

- 2022.03 - Now机器学习工程师, 语音识别与语言技术 @ Zoom
- 独立开展ASR/LLM的结合进行语音+文本模态sft的实验, 尝试提高ASR解码结果的一致性。目前在全格式的WER (词错率) 和正规化的RWER (稀有词词错率) 均取得优于产线模型相当的水平。

使用闭源LLM进行ASR error correction后处理, 从Zipformer-Transducer模型中导出N-best list, 结合biasing word list撰写prompt发送到Claude 3.5 Sonnet进行name entity修正, 离线实验在medical数据集上Rare word WER从37.8%变为17.5%。

训练语音识别和文本标点模型, 从零开始构建LAS-S2S丹麦语模型。测试数据集上的初始词错误率 (WER) 约为8%, 通过数据增强进一步降低了WER, 优于Microsoft Teams的结果。初始大小写和标点的整体F1约为70%。

独立完成Whisper推理支持的实现, 优化和性能评估 (WER, RTF/latency/throughput), 使用内部in-house VAD (人声检测) 模型和开源的WhisperX, 相比OpenAI的实现取得了更高的吞吐, 并在多数测试集上实现了更低的wer。

在LAS/seq2seq模型上实现基于多头注意力 (MHA) 的时间对齐, 从而提供良好的单词级时间戳, 以满足多语言转录的业务需求。[为此申请了一项美国专利]

维护 ASR 的推理仓库, 并解决线上的转录质量相关的问题。

撰写meta-prompt, 使用开源LLM模型 (比如Mistral MoE 8x7B) 生成几百个对话场景prompt, 并结合LLM模型生成的数字序列的不同读法 (reading format)。将两者结合创建对话场景下的带数字文本, 将文本交由同事使用内部/微软tts服务生成音频, 从而得到测试集和部分训练数据。将训练数据对产线模型进行微调后, 在另外的内部的digits数据集上有少量提升 (Absolute digit WER 降低约0.4%)
- 2019.08 - 2021.12数据科学家 @ Barclays
- 公司地址匹配和实体匹配, 没有内部GPU和可用的标签数据。使用主动学习方法解决。从构建一些小数据集开始, 只使用外部数据并训练一个XGBoost树, 然后在边界上标记样本并以迭代方式微调BERT模型。在CPU集群上使用我自己从头开始构建的基于DJL的管道完成了600万内部配对样本的推断。该模型在嘈杂的测试数据集上实现了94%的F1得分 (起初为89%)。模型在我们的Spark集群上以分布式方式进行离线推断。对于600万配对样本, 运行时间不到1小时 (在拥有80个CPU的集群上)。

使用历史平均值和Informer模型 (Transformer的变体) 预测聚合的用户交易活动 (转账数和转账金额)。然后构建反事实评估, 以评估系统停机对银行造成的财务损失, 并找出系统可靠性的关键时期。

教育背景

2018 - 2019	硕士, 网络科学与大数据分析 @ 伦敦大学学院, 优异
2016 - 2018	学士, 互联网计算 @ 利物浦大学*, 一等荣誉
2014 - 2016	学士, 信息与计算科学 @ 西交利物浦大学*

*注:2+2模式 (前两年在中国苏州, 后两年在英国利物浦), 双学位。

个人项目

- 2024.06 -关于病历数据在LLM上的微调与评估
- 使用十几万条中文病例数据, 在科室分类, 病历总结, 出院证明等任务上对不同的LLM foundation模型 (Llama3-instruct, Llama3中文-chat, Qwen2) 进行全量微调, 在域内测试数据集上, 微调后的数据集在问诊总结/出院总结等场景下的BLEU/ROUGH, 和科室分类的多分类accuracy上均取得了巨大的提升 (BLEU 0% ~ 30% -> 49% ~ 55%, ROUGE-L 20% ~ 30% -> 60% ~ 64%, Accauracy 0% ~ 36% -> 69% ~ 71%)。我们计划后续将数据开源。

技术分享

- "Accelerating Deep Learning on the JVM with Apache Spark and NVIDIA GPUs"
- 作者: Haoxuan Wang, Qin Lan [AWS], Carol McDonald [Nvidia]; 链接: https://www.infoq.com/articles/deep-learning-apache-spark-nvidia-gpu/?itm_source=articles_about_ai-ml-data-eng&itm_medium=link&itm_campaign=ai-ml-data-eng

早期项目

- 2019.06 - 2019.09项目实习 (硕士学位论文) @ Astroscreen
- 社交媒体帖子语言来源识别 (推文和Gab帖子) 项目。完成了Gab.com的语言 (帖子) 数据收集爬虫, 使用正则表达式进行数据预处理, 通过微调BERT和XLNet构建模型来分类这些数据的来源; 使用t-SNE可视化结果, 进行了"leave-one-hashtag-out"交叉验证, 并使用一些常见指标 (准确率、F1分数、混淆矩阵、马修斯相关系数) 评估模型。微调后, XLNet在标签均衡的测试数据集上显示了86%的F1分数, 而在随机均衡的测试数据集上为97%。结果显示了使用模型进行来源检查的潜力, 也表明了避免数据泄漏的重要性。
- 2019.02 - 2019.03将BERT和嵌入集成到CommonsenseQA挑战中
- 我们将Google BERT微调到CommonsenseQA挑战1.0 (每个问题有3个选项), 然后集成Conceptnet Numberbatch和ELMo嵌入, 试图提高模型性能。 该挑战包括一组需要人类常识知识的选择题。我们使用BERT + ELMo在验证集上达到了68.79%的准确率 (仅使用BERT: 67.47%; BERT + Numberbatch: 67.68%)。

技能

- 语言: Python, Java, C
- 深度学习, 语音识别和自然语言处理: PyTorch, HuggingFace, Whisper, K2, Transformers (和各种变种), LLM fine-tuning (LoRA, Full-paramter)
- 数据处理: Spark, Pandas
- 训练和系统基建: DeepSpeed, AsyncMQ/Kafka, Docker, Kubernetes (Istio, Knative, ...)
- 通用: Jenkins, git, JIRA