

- 2022.03 - Now

机器学习工程师，语音识别与语言技术 @ Zoom

Tech stack: Torch/Pytorch, ONNX, Kubernetes, Huggingface

- 实现并训练语音识别和文本标点模型，从零开始构建丹麦语模型。测试数据集上的初始词错误率（WER）约为**8%**，通过音素数据增强进一步降低了WER，优于**MS Teams的结果**。初始大小写和标点的整体F1约为**70%**。
 - 实现、测试、维护和评估推理系统的关键功能，包括**解码、多头注意力（MHA）时间戳生成和后处理代码**。
 - 在LAS/seq2seq模型上实现基于多头注意力（MHA）的时间对齐，从而提供良好的单词级时间戳，以满足多语言转录的业务需求。[为此申请了一项美国专利]
 - 撰写meta-prompt，使用开源LLM模型（比如Mistral MoE 8x7B）生成几百个对话场景prompt，并结合LLM模型生成的数字序列的不同读法（reading format）。将两者结合创建对话场景下的带数字文本，将文本交由同事使用内部/微软tts服务生成音频，从而得到测试集和部分训练数据。将训练数据对产线模型进行微调后，在另外的内部的digital数据集上有少量提升（Absolute digital WER 降低约0.4%）
 - （进行中）实验性质的对音频大模型的ASR能力进行内部评估，比如Qwen Audio, Whisper
 - 独立完成**Whisper**推理支持的实现，优化和性能评估（WER, RTF/latency/throughput），使用内部in-house VAD（人声检测）模型和开源的WhisperX，相比OpenAI的实现取得了更高的吞吐，并在多数测试集上实现了更低的wer。
 - 与下游Web和基础设施团队合作，简化离线转录系统架构和部署，以支持**35+**种单语言模型在**10+**个不同区域的**5+**个不同下游服务中使用。
 - 从头开始建立系统化的模型管理实践，以应对复杂的业务和语言需求。
 - 评估语音识别系统的性能，寻找最合适的参数以减少实时因素或提高系统的吞吐量。
 - 密切关注客户报告的产线错误，并通过代码或数据质量方面的改进进行修复。
 - 与硬件制造商（如Nvidia）合作，评估专有推理系统的推理性能，以降低推理的资源成本。
 - 一些正在进行的前沿探索：例如LLM重评分/生成式错误修正等。
- 2020.09 - 2021.12

数据科学家 @ Barclays

Tech stack: Spark / PySpark, Amazon Deep Java Library (DJL), Tensorflow / Keras, Pandas, Jupyter, 预训练Transformer / 似然比

- 公司地址匹配和实体匹配，没有内部GPU和可用的标签数据。使用主动学习方法解决。从构建一些小数据集开始，只使用外部数据并训练一个XGBoost树，然后在边界上标记样本并以迭代方式微调BERT模型。在CPU集群上使用我自己从头开始构建的基于DJL的管道完成了600万内部配对样本的推断。该模型在嘈杂的测试数据集上实现了**94%的F1得分（起初为89%）**。模型在我们的Spark集群上以分布式方式进行离线推断。对于600万配对样本，运行时间不到1小时（在拥有80个CPU的集群上）。
 - 使用历史平均值和Informer模型（Transformer的变体）预测聚合的用户交易活动（转账数和转账金额）。然后构建反事实评估，以评估系统停机对银行造成的财务损失，并找出系统可靠性的关键时期。
 - 维护团队的Spark集群，并通过结合DJL / PySpark UDF与模型建立分布式推理管道。与我的一位同事合作，我们创建了一个团队范围的包，只需4行代码即可启动Spark会话，这显著减少了非分布式计算背景的同事使用Spark的开销。
- 2019.08 - 2020.09

Java 后端开发工程师 @ Barclays

Tech stack: Openshift (Kubernetes), GridGain, Maven, Gradle, Wiremock, Mockito, Spring Boot

- 端到端功能开发、测试（单元、功能、性能）、部署（CD）
 - 为现有API添加缓存层，以减少重复数据访问的延迟
 - 将遗留代码迁移到内部Spring Boot模板，并进行重构以提高代码可读性和性能
 - 从头开始构建便捷的内部工具（如git hooks）和脚本（python / bash），以自动化软件开发过程

教育背景

2018 - 2019	硕士，网络科学与大数据分析 @ 伦敦大学学院， 优异
2016 - 2018	学士，互联网计算 @ 利物浦大学*， 一等荣誉
2014 - 2016	学士，信息与计算科学 @ 西交利物浦大学*

*注:2+2模式（前两年在中国苏州，后两年在英国利物浦），双学位。

早期项目

- 2019.06 - 2019.09

项目实习 (硕士学位论文) @ Astroscreen

社交媒体帖子语言来源识别（推文和Gab帖子）项目。 完成了Gab.com的语言（帖子）数据收集爬虫，使用正则表达式进行数据预处理，通过微调BERT和XLNet构建模型来分类这些数据的来源， 使用t-SNE可视化结果，进行了"leave-one-hashtag-out"交叉验证，并使用一些常见指标（准确率、F1分数、混淆矩阵、马修斯相关系数）评估模型。 微调后，XLNet在标签均衡的测试数据集上显示了86%的F1分数，而在随机均衡的测试数据集上为97%。结果显示了使用模型进行来源检查的潜力，也表明了避免数据泄漏的重要性。
- 2019.02 - 2019.03

将BERT和嵌入集成到CommonsenseQA挑战中

我们将Google BERT微调调到CommonsenseQA挑战1.0（每个问题有3个选项），然后集成Conceptnet Numberbatch和ELMo嵌入，试图提高模型性能。 该挑战包括一组需要人类常识知识的选择题。我们使用BERT + ELMo在验证集上达到了68.79%的准确率（仅使用BERT: 67.47%; BERT + Numberbatch: 67.68%）。

技术分享

- "Accelerating Deep Learning on the JVM with Apache Spark and NVIDIA GPUs"

作者: Haoxuan Wang, Qin Lan [AWS], Carol McDonald [Nvidia]; 链接: https://www.infoq.com/articles/deep-learning-apache-spark-nvidia-gpu/?itm_source=articles_about_ai-ml-data-eng&itm_medium=link&itm_campaign=ai-ml-data-eng